

Tarea 1: Análisis exploratorio de datos

Fecha de entrega: Viernes 11 de septiembre, 23:59 horas

Objetivo

El objetivo de esta tarea es realizar un análisis exploratorio de datos (EDA) orientado a una pregunta de investigación. No se busca aplicar automáticamente una lista de gráficos. La idea es usar los datos para comprender la muestra, identificar patrones y relaciones entre features, detectar limitaciones o sesgos, formular interpretaciones e hipótesis y generar nuevas preguntas. **Cada figura debe ayudar a responder una pregunta.**

Datos y desafíos

Cada grupo deberá trabajar con uno de los cuatro datasets propuestos. Cada dataset viene acompañado de un **desafío inicial**. Este desafío no necesariamente puede responderse de manera directa con los datos disponibles. Parte del trabajo consiste justamente en reconocer qué podemos concluir, qué no podemos concluir y qué información adicional sería necesaria.

- **Exoplanetas**

- **Desafío:** ¿La población de exoplanetas observada representa realmente la población de planetas que existe?
- **Algunas ideas de exploración:** relaciones entre masa/radio/período; diferencias por método de detección; poblaciones extremas; posibles sesgos observacionales
- **Datos:** en aula archivo `hwc.csv` (descargado desde [acá](#)), para información del catálogo y las columnas puedes consultar la documentación oficial del [NASA Exoplanet Archive](#).

- **Terremotos**

- **Desafío:** ¿Podemos afirmar, a partir de estos datos, que últimamente está temblando más?
- **Algunas ideas de exploración:** magnitud y profundidad; diferencias regionales; evolución temporal; concentración espacial
- **Datos:** en aula, archivo `earthquakes.csv`, para información del catálogo consultar [documentación de USGS](#)

- **Cambio climático**

- **Desafío:** ¿Los datos de temperatura permiten demostrar por sí solos cuál es la causa del calentamiento observado?
- **Algunas ideas de exploración:** comparación entre décadas; diferencias regionales; tendencia vs variabilidad; años extremos
- **Datos:** Dataset de Kaggle "[Climate Change: Earth Surface Temperature Data](#)". Hay varias tablas en este set de datos, elijan al menos una, aunque pueden usar más dependiendo de su análisis. Se sugiere empezar por `GlobalLandTemperaturesByMajorCity.csv` o `GlobalLandTemperaturesByCountry.csv`

- **Pokémon**

- **Desafío:** ¿Dos Pokémon con un poder total similar son necesariamente similares?
- **Algunas ideas de exploración:** perfiles de stats; diferencias entre tipos; trade-offs entre ataque/defensa/velocidad; outliers.
- **Datos:** Dataset de Kaggle "[The Complete Pokemon Dataset](#)"

Formule su pregunta de investigación

Después de explorar inicialmente la base de datos, escriba claramente una pregunta que pueda investigarse con las features disponibles. La pregunta debe ser lo suficientemente específica como para orientar el análisis, pero no es necesario conocer de antemano su respuesta.

Comprenda la muestra

Antes de analizar relaciones, describa brevemente:

- ¿qué representa una observación?
- ¿qué población está siendo estudiada?
- ¿cuáles son las principales features?
- ¿qué tipo de información contiene cada una?
- ¿existen valores faltantes, valores extremos o problemas de calidad?
- ¿hay alguna limitación importante en la forma en que se obtuvieron los datos?

No es necesario mostrar todas las salidas de Python. Seleccione solo la información que ayude a comprender la muestra.

Explore los datos para responder su pregunta

Construya un análisis exploratorio que le permita responder progresivamente su pregunta.

Considere, cuando sea relevante: distribuciones de features importantes, relaciones entre dos features, features que contienen información similar, distintos grupos o poblaciones, relaciones que cambian al incorporar una tercera feature, valores extremos; patrones inesperados.

No existe un número obligatorio de histogramas, boxplots o scatter plots. No se evaluará positivamente agregar figuras que no aporten al análisis.

Incorpore contexto

Incluya al menos un análisis en el que investigue si una relación cambia al considerar otra feature o al dividir la muestra en grupos.

Por ejemplo: una relación que cambia entre distintas regiones, una tendencia diferente según método de detección, diferentes perfiles dentro de una misma población, grupos que siguen comportamientos distintos, etc.

Explique qué información adicional aparece al agregar este contexto.

Encuentre algo inesperado

Identifique al menos un resultado que no esperaba encontrar.

Para ese resultado, distinga claramente:

- Observación: ¿qué muestran directamente los datos?
- Hipótesis: ¿qué posible explicación propone?
- Evidencia adicional: ¿qué información necesitaría para evaluar esa hipótesis?

Elija su figura clave

Seleccione una figura que considere la más importante de su investigación.

Explique brevemente:

- ¿qué pregunta responde?
- ¿qué patrón muestra?

- ¿por qué es importante para su interpretación?

La figura debe ser clara y contener ejes, unidades, leyenda y etiquetas apropiadas.

Responda el desafío inicial

Vuelva ahora a la pregunta planteada al inicio para su dataset y respóndala de acuerdo a las conclusiones de su EDA. Lo importante es justificar su respuesta utilizando la evidencia encontrada durante el EDA. Es perfectamente posible que pueda concluir que no puede responderla con los datos disponibles, pero debe justificarla.

Conclusión

Finalice el notebook con una conclusión breve que resuma los aspectos más importantes y notorios encontrados en su EDA

Posible problema de Machine Learning

A partir de lo que aprendieron durante el análisis exploratorio, imaginen que quisieran continuar este trabajo utilizando Machine Learning. Propongan un problema de predicción que tenga sentido con estos datos. **No deben implementar ni entrenar ningún modelo.**

Expliquen brevemente:

- ¿Qué intentarían predecir?
- ¿Qué features utilizarían como información de entrada?
- ¿Sería un problema de clasificación o de regresión? ¿Por qué?
- ¿Qué observaciones de su EDA sugieren que podría existir información útil para realizar esa predicción?
- ¿Qué dificultades anticipan? Por ejemplo: datos faltantes, clases desbalanceadas, pocas observaciones, outliers, features muy relacionadas entre sí o posibles sesgos en la muestra.

No es necesario que el problema de Machine Learning coincida exactamente con su pregunta de investigación. Lo importante es que la propuesta surja de lo que aprendieron al explorar los datos.

Entrega

Entregar un notebook ejecutado que contenga el código, las figuras, comentarios, respuestas e interpretaciones en celdas Markdown y una conclusión final. No se evaluará la cantidad de código ni la cantidad de figuras, sino la capacidad de hacer preguntas, seleccionar evidencia relevante e interpretar los resultados con criterio.

Presentación oral

Cada grupo deberá presentar los principales resultados de su análisis. La presentación no debe ser un recorrido paso a paso por el notebook, sino una historia construida a partir de los datos.

Deberán presentar su pregunta de investigación, los aspectos más relevantes de la muestra, las figuras necesarias para seguir el razonamiento, los principales hallazgos, algún resultado inesperado y las limitaciones del análisis. No es necesario mostrar todas las figuras del notebook: deberán seleccionar aquellas que sean esenciales para comunicar sus resultados.

Además, deberán identificar cuál consideran su figura clave y explicar por qué representa el hallazgo más importante del trabajo.

Finalmente, deberán presentar brevemente el problema de Machine Learning que propondrían como continuación del análisis: qué intentarían predecir, qué información utilizarían y qué dificultades anticipan.

Premio especial

Se otorgarán **5 puntos extra en el certamen** al grupo que presente la **mejor visualización de datos**, considerando claridad y diseño que mejor comunique un resultado relevante de su análisis.

Uso de herramientas de IA

Se permite el uso de herramientas de IA como apoyo para programación, depuración de código, visualización y redacción. Sin embargo, la pregunta de investigación, las decisiones de análisis, la interpretación de los resultados y las conclusiones deben ser desarrolladas y comprendidas por el grupo. Si utilizan IA de manera sustantiva, indiquen brevemente al final del notebook qué herramienta utilizaron y para qué. Durante la presentación, ambos integrantes deben ser capaces de explicar y justificar cualquier parte del análisis entregado.

La IA puede apoyar el trabajo, pero no reemplazar el razonamiento del grupo.